SyncCrawl™ | Tier 3 · 적응형 분산 크롤링 및 데이터 정제 | 제품 소개서 겸 도입 제안서

SyncCrawl™ : 적응형 웹 데이터 수집 및 RAG 지식 자산화 플랫폼

수집 대상 웹사이트의 화면 구조가 바뀌어도 문맥을 파악해 수집을 이어가고, 모아온 데이터를 깔끔하게 정제해 사내 분석·AI 지식베이스(RAG)로 만들어 주는 플랫폼입니다.

주식회사 엠파시 (Empasy)
문서번호: EMP-2026-P09
공식문서: doc.empasy.com

EXECUTIVE SUMMARY · SYNCCRAWL™ 핵심 요약

SyncCrawl™은 아모레퍼시픽 글로벌 SNS 수집 및 효성ITX 스마트 크롤링 구축에서 검증된 엔터프라이즈 웹 수집 플랫폼입니다. 수집 관리 서버, 시나리오 분석기, 브라우저 실행 워커를 3계층으로 분리해 안정성을 높였으며, 수집한 데이터를 광고·태그 없이 정제해 사내 분석 DB와 AI 지식베이스(RAG)에 바로 적재합니다.

01. 한눈에 보는 도입 기대 지표

Key Highlights

약 80% 절감
크롤러 유지보수 공수
사이트 개편 시 선택자 자동 보정

4대 컨테이너
Server · Agent · Console 분리
Kubernetes(AKS) 대규모 분산 수집

RAG 직결
노이즈 제거 및 벡터 자산화
광고·태그 제거 후 pgvector 저장

대기업 실증
엔터프라이즈 상용 구축 완료
아모레퍼시픽·효성ITX 구축 실적

02. 도입 부서 주요 고민 및 SyncCrawl™ 해결 방안 조견표

Requirement & Solution Mapping

업무 영역	현업에서 자주 겪는 고민	SyncCrawl™ 해결 방법
사이트 개편 시 수집 중단	외부 사이트의 디자인이나 HTML 태그가 조금만 바뀌어도 크롤러가 멈춰서 개발자가 매번 고쳐야 함	**고정된 태그 위치만 보지 않고 페이지 안의 글자와 배치를 분석해 바뀐 데이터 위치를 스스로 다시 찾음**
운영자 관리 편의성	수집 일정을 바꾸거나 왜 에러가 났는지 보려면 개발자가 서버에 들어가 로그를 직접 뒤져야 함	**웹 기반 운영 콘솔(smart-crawling-console)에서 시나리오 등록, 즉시 실행, 상태·로그 확인을 한눈에 처리**
대규모 수집 및 차단 대응	여러 사이트에서 많은 데이터를 동시에 모을 때 세션이 꼬이거나 봇 차단에 걸려 수집이 실패함	**시나리오 생성 워커와 실행 워커를 분리하고, 동시 세션 중재 및 프록시 제어로 안정적인 수집 유지**
수집 데이터 AI 활용	긁어온 원본 HTML에 광고와 불필요한 메뉴가 섞여 있어 사내 AI(RAG)에 바로 넣으면 엉뚱한 답을 함	**본문과 핵심 필드만 깨끗하게 골라내고 의미 단위로 나누어(Chunking) 벡터 DB에 바로 저장**

Quick Access

온라인 문서 및 체험 안내
공식 기술 문서(**https://doc.empasy.com/synccrawl/**) 및 통합 포털(**https://sync.empasy.io**)에서 상세 가이드를 확인하실 수 있습니다.

구축형 엔터프라이즈 솔루션 (별도 시연 지원)

도입 배경 및 기존 업무 방식과의 비교

현재 업무에서 반복되는 불편함을 짚어보고, 도입 후 업무 흐름이 어떻게 간편해지는지 비교합니다.

주식회사 엠파시 (Empasy)
문서번호: EMP-2026-P09
공식문서: doc.empasy.com

01. 기존 업무 환경에서 자주 겪는 4가지 어려움

Current Pain Points

왜 기존 방식으로는 업무 속도와 품질을 동시에 높이기 어려울까요?

- 경쟁사 가격, 글로벌 SNS 반응, 공공 공고 등 외부 데이터를 모을 때 사이트 구조가 바뀔 때마다 수집기가 멈춰 데이터가 비게 됩니다.
- 크롤링 스크립트가 개발자 PC나 개별 서버에 흩어져 있어, 지금 어떤 수집 작업이 돌고 있고 어디서 실패했는지 관리하기 어렵습니다.
- 로그인 세션이 필요한 사이트나 동적 화면(SPA)은 일반 수집 도구로 가져오면 빈 화면(백색 화면)만 저장되는 경우가 많습니다.
- 수집한 데이터를 정제해 사내 분석 DB나 AI 지식 저장소에 넣는 과정이 수작업으로 나뉘어 있어 최신 정보 반영이 늦어집니다.

02. 기존 처리 방식(AS-IS) vs SyncCrawl™ 도입 후(TO-BE) 흐름 비교

Process Transformation

기존 수작업 중심 방식 (AS-IS)

반복 수작업 · 대기 발생

1. **개별 스크립트 수동 코딩**
   사이트마다 HTML 태그 위치를 찾아 코드 작성
2. **사이트 개편 시 수집 멈춤**
   클래스명 변경 시 빈 값 수집 또는 에러 중단
3. **서버 접속 후 수동 디버깅**
   개발자가 로그를 확인하고 선택자 코드 재배포
4. **수작업 데이터 정제·가공**
   불필요한 광고·태그를 수동으로 걸러낸 뒤 DB 적재

SyncCrawl™ 도입 후 (TO-BE)

간편 처리 · 안전 검증

1. **웹 콘솔에서 시나리오 설정**
   수집 대상 주소와 가져올 항목(상품명·가격·본문) 지정
2. **분산 에이전트 자동 수집**
   전용 워커가 렌더링 확인 및 화면 변경 시 위치 자동 보정
3. **콘솔에서 실시간 상태·로그 확인**
   DB 직접 접속 없이 웹 화면에서 성공·실패 즉시 점검
4. **자동 정제 및 RAG 지식 저장**
   노이즈 제거 후 정형 JSON 및 벡터 DB로 즉시 적재

03. 핵심 추진 방향 요약

Key Direction

방향 01 · 쉬운 사용성

복잡한 명령어 없이 직관적 처리

개발 지식이 없는 현업 담당자도 친숙한 웹 화면과 일상적인 언어로 원하는 작업을 바로 실행할 수 있습니다.

방향 02 · 안전한 통제

사람이 확인하고 언제든 복구

중요한 변경은 담당자가 눈으로 확인한 뒤 반영하며, 변경 직전 상태를 저장해 두어 실수가 생겨도 바로 되돌립니다.

방향 03 · 비용 효율화

반복 인건비 및 AI 요금 절약

수작업 공수를 줄이고, 캐시 재사용과 사내 경량 모델을 활용해 운영 비용 부담을 낮춥니다.

목표 시스템 구성도 및 권장 서버 사양

사용자 화면층 · 애플리케이션 및 AI 엔진층 · 데이터 및 인프라층의 3개 계층으로 분리된 안정적인 구조입니다.

주식회사 엠파시 (Empasy)
문서번호: EMP-2026-P09
공식문서: doc.empasy.com

01. SyncCrawl™ 3-Layer 통합 아키텍처 다이어그램

Target Architecture

ARCHITECTURE INDEX
계층별 핵심 역할 요약

- **L1 운영 관리자 콘솔** — smart-crawling-console (Vue 3) · 시나리오 빌더 · 실행 스케줄러 · 실시간 로그 뷰어
- **L2 3계층 분산 수집 서버** — smart-crawling-server(조율) · scenario-agent(규칙생성) · crawling-agent(브라우저 수집)
- **L3 정제·벡터 저장소** — PostgreSQL 17 · pgvector/Milvus/Qdrant · MinIO/Blob 원본 보관 · KeyVault 시크릿
- **GV 보안 및 안정성 통제** — SSRF 내부망 접근 차단 · 동시 세션 중재 · ABAC 접근 제어 · CodeQL/Semgrep 검증

엔터프라이즈 검증 아키텍처
Server · Scenario Agent · Crawl Agent 분리



02. 권장 서버 사양 및 기간계 연동 규격

Server Sizing & Integration Specs

구분	CPU	메모리 (RAM)	스토리지	비고 및 연동 표준
최소 사양 (단일 클러스터 수집)	**8 vCPU**	**16 GB RAM**	SSD 250 GB	**Server + Console + Crawl Agent 컨테이너 구성**
권장 사양 (대규모 분산 K8s/AKS)	**16~32 vCPU**	**32~64 GB RAM**	NVMe 1 TB+	**Crawl Agent 멀티 파드 오토스케일링 + pgvector**
사내 시스템 연동 표준	표준 REST API (`/api/v1/...`) · OAuth2/JWT SSO 통합 인증 · 표준 MCP 프로토콜 · JDBC Read/Write 연동			

핵심 작동 프로세스 및 4대 주요 기능

실제 업무가 어떤 순서로 처리되는지와 실무에서 바로 체감할 수 있는 4가지 핵심 기능을 안내합니다.

01. 4단계 업무 처리 프로세스 (Step-by-Step)

End-to-End Workflow

STEP 01 소요시간: 수 분 내

운영 콘솔에서 수집 시나리오 정의

관리자 웹 콘솔에서 수집할 사이트 주소와 추출할 항목(제목, 본문, 가격, 날짜 등), 실행 주기를 등록합니다.

STEP 02 소요시간: 자동 구성

시나리오 에이전트의 화면 분석 및 규칙 생성

시나리오 에이전트가 대상 페이지의 구조를 분석해 수집 규칙을 만들고, 사이트 개편 시에는 문맥을 보고 선택자를 보정합니다.

STEP 03 소요시간: 병렬 수집

크롤링 에이전트 분산 실행 및 렌더링 확인

독립된 크롤링 에이전트 컨테이너들이 동시에 수집을 수행하며, 화면이 정상적으로 떴는지 확인해 빈 화면 수집을 줄여줍니다.

STEP 04 소요시간: 실시간

노이즈 정제 및 분석 DB · 벡터 저장소 적재

불필요한 광고와 HTML 태그를 걷어내고 깔끔한 정형 데이터와 벡터 임베딩으로 변환해 분석 시스템과 AI에 공급합니다.

02. SyncCrawl™ 4대 핵심 기능 상세

Core Capabilities

핵심 기능 01 · 3계층 분리 구조

관리 서버 · 시나리오 분석 · 수집 워커 분리

관리 서버와 시나리오 분석기, 실제 브라우저 실행 워커를 독립 컨테이너로 분리해 대규모 수집 시에도 안정적으로 확장됩니다.

핵심 기능 02 · 선택자 자동 보정

웹사이트 개편에 대응하는 문맥 기반 위치 복구

대상 사이트의 레이아웃이나 태그 이름이 바뀌어도 주변 텍스트와 화면 구조를 파악해 수집이 끊기지 않도록 돕습니다.

핵심 기능 03 · 분석·마케팅 연계

SyncInsight · SyncShop · SyncCMS 데이터 공급

수집·정제된 외부 시세와 트렌드 데이터를 SyncInsight 분석, SyncShop 가격 조정 검토, SyncCMS 콘텐츠 작성으로 바로 연결합니다.

핵심 기능 04 · AI 지식 정제

사내 AI 활용도를 높이는 정제·분할 파이프라인

단순히 웹페이지를 가져오는 데 그치지 않고, 광고·노이즈를 제거한 뒤 문맥 단위로 나누어 사내 AI 지식 저장소에 공급합니다.

주요 화면 와이어프레임 프리뷰 및 기존 방식 비교

실무 담당자가 사용하는 주요 화면의 실제 구성 항목(테이블·상태 배지·연동 액션)과 기존 방식 대비 우위를 정리했습니다.

주식회사 엠파시 (Empasy)
문서번호: EMP-2026-P09
공식문서: doc.empasy.com

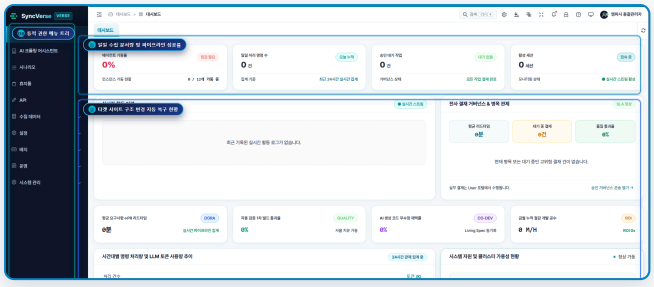
01. 실무자용 주요 화면 구성 및 핵심 데이터 프리뷰

Interactive UI Wireframe & Live Metrics

SCREEN 01 — smart-crawling-console

스마트 크롤링 통합 운영 콘솔

등록된 수집 시나리오 목록, 워커 상태, 일별 수집 현황과 스케줄 일정을 한 화면에서 관리합니다.

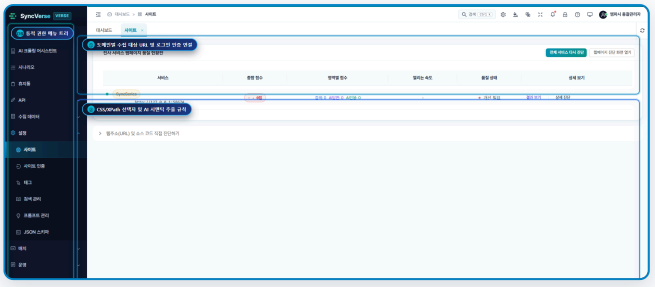


- ✓ 수집 시나리오 통합 관리
- ✓ 일별 수집 성공률 표시
- ✓ 스케줄 주기 간편 변경

SCREEN 02 — /scenarios/builder

실사이트 기반 시나리오 빌더

수집 대상 웹페이지를 미리 보면서 추출 항목(상품명·가격·본문)을 지정하고 문맥 기반 복구 기준을 설정합니다.

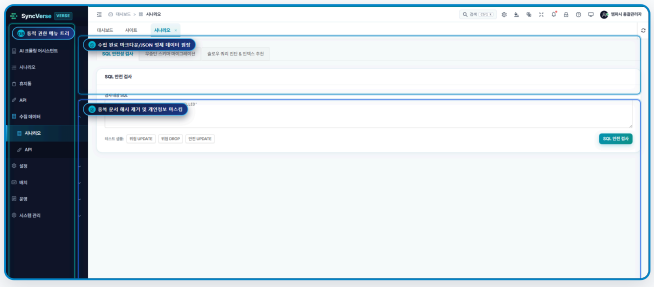


- ✓ 웹 화면 미리보기 선택
- ✓ 문맥 기반 위치 추론
- ✓ 빈화면 수집 방지 설정

SCREEN 03 — /executions/logs

분산 워커 실행 상태 및 실시간 로그 뷰어

DB나 서버 터미널에 접속하지 않고 웹 콘솔에서 각 수집 에이전트의 실행 로그와 캡처 화면을 확인합니다.

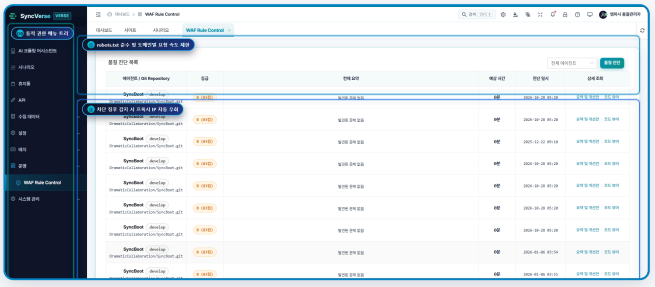


- ✓ 워커별 실시간 실행 로그
- ✓ 실패 구간 캡처 이미지
- ✓ 콘솔에서 바로 재실행

SCREEN 04 — /knowledge/pipeline

데이터 정제 및 분석·콘텐츠 시스템 연동

수집된 원본 HTML에서 불필요한 태그를 제거해 JSON과 벡터 데이터로 변환하고 사내 분석·콘텐츠 시스템으로 전달합니다.



- ✓ 원본 HTML vs 정제 J...
- ✓ 문단 분할 미리보기
- ✓ 지식DB 저장 상태 확인

02. 기존 운영 방식 대비 SyncCrawl™ 비교표

Before vs After Comparison

비교 항목	기존 수작업 · 일반 도구 환경	SyncCrawl™ 도입 환경
대상 사이트 UI 변경 시	선택자 오류로 수집 중단 (개발자 수동 코드 수정 필요)	**문맥 기반 선택자 자동 보정으로 수집 연속성 확보**
수집 현황 및 로그 확인	개발자가 서버나 DB에 직접 접속해 로그 파일 확인	**운영자 전용 웹 콘솔에서 실행 상태·로그 실시간 조회**
보안 및 비밀키 관리	설정 파일에 계정·API 키 평문 저장 위험	**KeyVault CSI 연동 및 SSRF 내부망 접근 차단 기본 적용**
AI(RAG) 데이터 연동	수집 후 별도 정제 프로그램을 다시 개발해야 함	**노이즈 제거·청킹·벡터 DB 적재까지 한 파이프라인으로 처리**

보안 관리 대책, 운영 비용(TCO) 절감 및 도입 에디션

기업 내부 데이터를 안전하게 보호하는 보안 체계와 AI·인프라 운영 비용 절감 방안, 맞춤형 도입 에디션입니다.

주식회사 엠파시 (Empasy)
문서번호: EMP-2026-P09
공식문서: doc.empasy.com

SECURITY · COST OPTIMIZATION · LICENSING EDITIONS

사내 폐쇄망·전용 클라우드 설치로 데이터 유출 걱정을 덜고, 사내 모델·캐시 활용으로 고정비 안에서 경제적으로 운영합니다.

01. 엔터프라이즈 3대 보안 및 안전 관리 대책

Security & Governance

보안 대책 01

SSRF(서버 측 요청 위조) 차단 및 URL 검증

크롤러가 허용되지 않은 내부망 주소나 비정상 리다이렉트로 접근하지 못하도록 URL 검증기가 사전 차단합니다.

보안 대책 02

KeyVault CSI 기반 시크릿 관리 및 ABAC 권한 제어

인증 정보와 암호키를 YAML에 평문으로 두지 않고 보안 볼트에서 주입하며, 속성 기반 접근 제어(ABAC)로 데이터를 보호합니다.

보안 대책 03

CodeQL · Semgrep 정적 보안 검증 및 폐쇄망 지원

소스코드 보안 취약점 점검을 상시 수행하며, 외부망과 분리된 사내 환경에서도 내부 LLM과 연동해 안전하게 동작합니다.

02. 운영 비용(TCO) 및 리소스 절감 비교

Cost Optimization Analysis

비용 항목	기존 방식 (수작업 · 외부 유료 API 전면 의존)	SyncCrawl™ 최적 운영안 (자동화 · 캐시/사내GPU 결합)
크롤러 유지보수 개발 인건비	사이트 개편 때마다 수집 스크립트 수정에 상시 인력 투입	**적응형 선택자 보정과 웹 콘솔 관리로 유지보수 공수 대폭 절감**
데이터 정제 및 전처리 비용	원시 HTML 정제 및 RAG 변환용 별도 파이프라인 구축	**수집과 동시에 정형화·벡터화까지 일괄 처리해 구축비 절약**
인프라 운영 효율성	수집기마다 개별 가상머신(VM) 상시 가동	**Kubernetes 기반 멀티 레플리카 구조로 수집 시간대에만 탄력 운영**

03. 고객사 환경 및 예산에 맞춘 3가지 도입 방식

Deployment Options

방식 A · 시범 도입 (PoC)

단기 파일럿 검증형 (2~4주)

주요 업무 1~2건을 대상으로 단일 서버에 빠르게 구성하여 실제 업무 개선 효과와 현장 적합성을 먼저 확인합니다.

방식 B · 전용 클라우드 (VPC)

고객사 전용 클라우드형

고객사 전용 클라우드(AWS/NCP/Azure) 내부에 구축하며, 사내 계정 연동·단계별 승인·자동 백업을 함께 지원합니다.

방식 C · 사내 구축형 (On-Premise)

사내망 독립 설치형

외부 인터넷과 분리된 자체 서버 및 사내 GPU 환경에 설치하여 소스코드와 내부 데이터의 외부 반출을 예방합니다.

단계별 도입 추진 일정(WBS), 품질 점검 기준 및 산출물 안내

시범 검증(PoC)부터 본 구축, 4종 기본 산출물 정리 및 담당자별 순차 확인까지 단계별로 진행합니다.

주식회사 엠파시 (Empasy)
문서번호: EMP-2026-P09
공식문서: doc.empasy.com
페이지:
7 / 8

01. 3단계 표준 도입 일정 및 주요 과업 (WBS)

Implementation Roadmap

추진 단계	소요 기간	주요 수행 과업 내용	제공 산출물
1단계: 수집 대상 분석 및 시범 구성	**1~2주차 (2주)**	핵심 타겟 사이트 5~10곳 선정 · 수집 스키마 정의 및 시나리오 에이전트 검증	수집 대상 분석서 · 시범 수집 데이터
2단계: 분산 클러스터 및 콘솔 구축	**3~6주차 (4주)**	Server/Agent/Console 컨테이너 배포 · KeyVault 보안 적용 · RAG 벡터 DB 연동	아키텍처 구성도 · 연동 명세서
3단계: 안정화 및 운영자 교육	**7~8주차 (2주)**	대량 수집 스케줄 리허설 · 운영 콘솔 시나리오 관리 및 로그 점검 실습 교육	운영자 매뉴얼 · 완료보고서

02. 단계별 품질 점검 기준 및 담당자 확인 절차

Quality Check & Approval

점검 01 · 설계/산출물

4종 산출물 일치 여부

프로그램사양서·화면설계서·테이블명세서·TC가 실제 코드 및 DB 구조와 맞게 갱신되었는지 확인합니다.

점검 02 · 빌드/테스트

실제 데이터 & 테스트 범위

실제 DB 연동 동작 여부와 자동 빌드·단위 테스트 범위 기준(80% 수준) 통과 여부를 점검합니다.

점검 03 · 1,045개 TC 검증

5가지 관점 TC & 백업 복원

전사 1,045개 표준 테스트케이스(정상·입력값·경계값·상태·권한, L1~L5) 100% 통과 및 스냅샷 복원을 검증합니다.

점검 04 · 단계별 승인

담당자 순차 확인 및 이관

개발자→기획자→보안담당자→관리자 확인 절차를 점검하고 현업 실습 교육 후 운영을 지원합니다.

03. 수행 조직 및 검수 역할 분담

Project Organization & Roles

역할 구분	주요 담당 업무	고객사 협업 및 확인 단계
PM / 솔루션 아키텍트	전체 일정·품질 관리, 사내 시스템(SSO/ERP/DB) 연동 구조 및 보안 설계	도입 범위 협의 및 주간 진행 상황·산출물 확인
도메인·AI 엔지니어	SyncCrawl™ 구축, 업무 기준·프롬프트 설정, 빌드 및 테스트 환경 구성	1차 기술 확인(개발) · 3차 보안/개인정보 기준 확인
QA / 변화관리 담당	5가지 관점 테스트케이스 실행 점검, 운영자·현업 가이드 작성 및 실습 교육	2차 요건 확인(기획/현업 테스트) · 오픈 확인

도입 기대 효과(ROI), 주요 활용 사례 및 기술 지원

도입 전후의 실질적인 업무 개선 효과와 안정적인 운영을 뒷받침하는 3단계 기술 지원 체계입니다.

주식회사 엠파시 (Empasy)
문서번호: EMP-2026-P09
공식문서: doc.empasy.com
페이지:
8 / 8

01. 도입 전·후 기대 효과 비교 (ROI)

Expected Benefits

측정 항목	도입 전 (기존 방식)	SyncCrawl™ 도입 후	개선 효과
신규 사이트 수집 시나리오 등록	사이트당 2~3일 (개발자 스크립트 코딩 및 배포)	30분 내외 (콘솔 및 시나리오 에이전트 활용)	구축 속도 대폭 향상
사이트 개편에 따른 수집 중단 시간	오류 인지부터 코드 수정 배포까지 수일 공백	문맥 기반 선택자 보정 및 콘솔 즉시 조치	유지보수 공수 80% 절감
외부 데이터 사내 AI(RAG) 반영 주기	수집 후 수동 전처리를 거쳐 주/월 단위 반영	수집-정제-벡터 적재 자동 연결로 일 단위 최신화	최신 시장 정보 확보

02. 추천 도입 대상 및 주요 활용 시나리오

Use Cases & References

활용 분야 01

아모레퍼시픽 글로벌 SNS 크롤링 구축 (실증 완료)

국내외 주요 SNS 및 뷰티 채널의 소비자 반응·트렌드 데이터를 안정적으로 수집·분석하는 파이프라인 구축

활용 분야 02

효성ITX 스마트 크롤링 시스템 구축 (실증 완료)

대규모 웹 데이터 수집 시나리오를 중앙 콘솔에서 관리하고 고가용성 분산 에이전트로 실행하는 엔터프라이즈 환경 구축

03. 3단계 전담 기술 지원 및 유지보수 체계 (SLA)

Maintenance & Support

LEVEL 1 · 헬프데스크

15분 내 초동 응답

온라인·유선 기술 지원 창구를 통해 사용법 문의 및 설정 변경을 빠르게 안내합니다.

LEVEL 2 · 전담 엔지니어

1시간 내 원인 분석·복원

연동 이상 발생 시 로그 분석과 스냅샷 원상 복원을 통해 업무 지연을 최소화합니다.

LEVEL 3 · 코어 연구소

정기 점검 및 기능 패치

분기별 성능·보안 정기 점검 리포트를 제공하고 코어 엔진 업데이트를 지원합니다.

CONTACT & LIVE DEMO

주식회사 엠파시 (Empasy Inc.) | 대표이사 오병문 (사업자번호: 547-81-03408)
서울특별시 금천구 가산디지털1로 205-27 2층 208호 · 도입 문의: poh@empasy.com / 0507-1360-8169

공식 홈페이지: **https://empasy.io**
통합 데모 포털: **https://sync.empasy.io**
기술 문서 포털: **https://doc.empasy.com**